



- 본 과제는 학회 정규 세션 「Linear Algebra」, 「Basic Statistics」 및 「Math for ML」 일부 내용을 다루며, 개념의 이해와 실제 활용 사례에 대한 이해를 돋기 위해 기획되었습니다. 평가를 위한 것이 아니므로, 주어진 힌트를 적극 활용하시고 학회원 간 토론, Slack의 질의응답을 활용하여 해결해주십시오. 단, 답안 표절은 금지합니다.
- 2/11 (수) 23시 59분까지 Github에 PDF 파일 하나로 제출해주십시오. Github에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 활용해주십시오.

문제 1 선형대수 기초 (Linear Algebra Basic)

1. $Ax = b$ 의 동치 조건

$n \times n$ 정사각행렬 A 에 대하여 다음 조건들은 동치(equivalent)입니다.

- (a) 행렬 A 는 가역적(invertible)이다.
- (b) 임의의 $n \times 1$ 벡터 b 에 대하여 방정식 $Ax = b$ 는 유일한 해를 갖는다.
- (c) 동차 방정식(Homogeneous equation) $Ax = 0$ 은 오직 자명한 해(trivial solution, $x = 0$)만을 갖는다.

1-1. 다음과 같은 삼변수 함수 $f(x, y, z)$ 가 주어져 있습니다.

$$f(x, y, z) = x^2 + y^2 + 1.5z^2 + xy + yz + zx$$

- (1) 이 함수의 헤시안 행렬(Hessian Matrix) A 를 구하고 PD(Positive Definite), PSD, ND, NSD 중 무엇인지 판별하시오.
- (2) 위에서 구한 행렬 A 의 역행렬 A^{-1} 을 계산하시오.
- (3) 만약 특정 상수 k 에 대해 함수의 항 xy 가 kxy 로 변하여 $\det(A) = 0$ 이 된다면, 조건 (b)는 여전히 성립하는가? 그 이유를 행렬식(determinant)과 관련지어 설명하시오.

1-2. (Optional)

- (1) (a), (b), (c) 세 조건들이 동치임을 증명하시오.
- (2) 행렬 A 가 가역적이라고 가정할 때, 임의의 b 에 대하여 $Ax = b$ 를 만족하는 해 x 가 항상 존재함을 대수적으로 유도하여 증명하고 해당 증명의 의미를 서술하시오.

$$1-1. \quad f(x, y, z) = x^2 + y^2 + 1.5z^2 + xy + yz + zx$$

(1)

$$A = \nabla^2 f = \begin{bmatrix} f_{xx} & f_{xy} & f_{xz} \\ f_{yx} & f_{yy} & f_{yz} \\ f_{zx} & f_{zy} & f_{zz} \end{bmatrix}$$

$$f_x = 2x + y + z$$

$$f_{xx} = 2, \quad f_{xy} = 1, \quad f_{xz} = 1$$

$$f_y = 2y + x + z$$

$$f_{yy} = 2, \quad f_{yz} = 1, \quad f_{yx} = 1$$

$$f_z = 3z + x + y$$

$$f_{zz} = 3, \quad f_{zx} = 1, \quad f_{zy} = 1$$

$$\therefore A = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 3 \end{bmatrix}$$

$$\Delta_1 = 2 > 0$$

$$\Delta_2 = \begin{vmatrix} 2 & 1 \\ 1 & 2 \end{vmatrix} = 4 - 1 = 3 > 0$$

$$\begin{aligned} \Delta_3 &= \det(A) = 2(6-1) - 1(3-1) + 1(1-2) \\ &= 10 - 2 + 1 = 7 > 0 \end{aligned}$$

$\therefore \Delta_1 > 0, \Delta_2 > 0, \Delta_3 > 0$ 이므로 $A \in PD$.

$$(2) \quad A = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 3 \end{bmatrix}, \quad \det(A) = 7$$

$$A^{-1} = \frac{1}{\det(A)} \text{adj}(A) = \frac{1}{7} \begin{bmatrix} 5 & -2 & -1 \\ -2 & 5 & -1 \\ -1 & -1 & 3 \end{bmatrix}$$

$$(3) \quad f_{xy} = k$$

$$A(k) = \begin{bmatrix} 2 & k & 1 \\ k & 2 & 1 \\ 1 & 1 & 3 \end{bmatrix}$$

$$\det(A(k)) = 0 \text{ 이 되는 } k \Rightarrow \det(A(k)) = - (k-2)(3k+4)$$

$$k=2 \text{ or } -\frac{4}{3} \text{ 일 때 } \det=0$$

$\therefore \det(A) = 0$ 이면 A 는 PD 이 아니고 PD (b)에 속하지 않습니다.

문제 2 특이값 분해 (SVD)

특이값 분해(SVD)는 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

- 항상 대칭 행렬을 이루는 두 행렬 $B^T B, BB^T$ 를 계산하고, 이들의 고유값을 계산해 특이값 σ 와 고유 벡터를 통해 직교대각화하여 $B^T B = V D V^T, BB^T = U D U^T$ 를 구합니다.
- 0이 아닌 특이값들을 내림차순으로 나열하여 Σ 를 구성하고, 이들을 모두 활용해 $A = U \Sigma V^T$ 를 구합니다.

다음 행렬 B 에 특이값 분해를 적용하였을 때 나오는 행렬 U, Σ, V^T 를 각각 구하시오.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad B^T = \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$B^T B = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = V D V^T$$

$$B B^T = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} = U D U^T$$

$$\det(B^T B - \lambda I) = ((-\lambda) \lambda (\lambda - 2)) = 0$$

$$\lambda_1 = 2, \lambda_2 = 1$$

$$\lambda = 2, 1, 0$$

$$i) \lambda_1 = 2 \rightarrow (B^T B - 2I) v = 0$$

$$i) \lambda_1 = 2 \rightarrow (B^T B - 2I) v = 0$$

$$\begin{bmatrix} -1 & 1 & 0 \\ 1 & -1 & 0 \\ 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} -v_1 + v_2 = 0 \\ v_1 - v_2 = 0 \\ -v_3 = 0 \end{bmatrix}$$

$$V = t \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

$$V_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

$$ii) \lambda_2 = 1 \rightarrow (B^T B - I) v = 0$$

$$\begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = 0 \quad \begin{bmatrix} v_1 = 0 \\ v_2 = 0 \\ v_3 = 1 \end{bmatrix}$$

$$V = t \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$V_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$iii) \lambda_3 = 0 \rightarrow (B^T B) v = 0$$

$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = 0 \quad \begin{bmatrix} v_1 + v_2 = 0 \\ v_3 = 0 \end{bmatrix}$$

$$V_3 = t \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$$

$$i) \lambda_1 = 2 \rightarrow (B B^T - 2I) u = 0$$

$$\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix}$$

$$\begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \end{bmatrix} = 0 \quad m_2 = 0$$

$$m_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$ii) \lambda_2 = 1 \rightarrow (B B^T - I) u = 0$$

$$\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \end{bmatrix} = 0 \quad m_1 = 0 \quad m_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$V = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\sigma = \sqrt{\lambda(BB^T)} \Rightarrow \sigma_1 = \sqrt{2}, \sigma_2 = 1$$

$$\therefore V = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \end{bmatrix}$$

$$\therefore \Sigma = \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

$$\therefore U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

문제 3 Convex Sets & Functions

3-1. Convex Set

1. 다음 집합들이 Convex set인지 증명하시오.

$$C_1 = \{(x, y) \in \mathbb{R}^2 : x + y \leq 1\}$$

$$C_2 = \{x \in \mathbb{R}^n : \|x\|_1 \leq 1\}$$

$$C_3 = \{(x, y) \in \mathbb{R}^2 : y \geq e^x\}$$

2. 함수 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 가 convex function일 때, f 의 epigraph인 집합 S 가 convex set임을 보이시오.

$$S = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} : t \geq f(x)\}$$

3-2. Convex Function

1. Convex 함수의 합성

$f : \mathbf{R}^d \rightarrow \mathbf{R}$ 가 실수 값을 갖는 함수라고 합시다.

(a) 함수 $f(x)$ 와 $g(x)$ 가 convex일 때, $f(x) + g(x)$ 또한 convex임을 보이시오.

(b) A 와 b 가 호환되는 크기의 행렬과 벡터라고 합시다. $f(x)$ 가 convex라면 $f(Ax + b)$ 또한 convex임을 보이시오.

2. Convex Optimization

또 다른 함수 $f : \mathbf{R}^d \rightarrow \mathbf{R}$ 를 고려해 봅시다.

$$f(x) = \|Ax - b\|^2.$$

오직 convex 함수의 정의만을 사용하여, $f(x)$ 가 $x \in \mathbf{R}^d$ 에서 convex임을 보이시오.

3-1. (1)

$$(a) C_1 = \{(x, y) \in \mathbb{R}^2 : x+y \leq 1\}$$

임의의 두 점 $(x_1, y_1), (x_2, y_2) \in C_1$

$$x_1+y_1 \leq 1, x_2+y_2 \leq 1$$

$\lambda \in [0, 1]$ 에 대해

$$(x, y) = \lambda(x_1, y_1) + (1-\lambda)(x_2, y_2)$$

$$x = \lambda x_1 + (1-\lambda) x_2$$

$$y = \lambda y_1 + (1-\lambda) y_2$$

$$x+y = \lambda(x_1+y_1) + (1-\lambda)(x_2+y_2)$$

그때 $x_1+y_1 \leq 1, x_2+y_2 \leq 1$

$$\therefore x+y \leq \lambda \cdot 1 + (1-\lambda) \cdot 1 = 1$$

$$(x, y) \in C_1$$

$\therefore C_1$ 은 convex.

$$(b) C_2 = \{x \in \mathbb{R}^2 : \|x\|_1 \leq 1\}$$

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

임의의 $x_1, x_2 \in C_2$, 즉 $\|x_1\|_1 \leq 1, \|x_2\|_1 \leq 1$

$$x = \lambda x_1 + (1-\lambda) x_2$$

$$\|x\|_1 = \|\lambda x_1 + (1-\lambda) x_2\|_1$$

$$\leq \lambda \|x_1\|_1 + (1-\lambda) \|x_2\|_1$$

$$\leq \lambda \cdot 1 + (1-\lambda) \cdot 1 = 1$$

$\therefore x \in C_2$

C_2 은 convex

$$(c) C_3 = \{(x, y) \in \mathbb{R}^2 : y \geq e^x\}$$

e^x 는 convex.

임의의 두 점 $(x_1, y_1), (x_2, y_2) \in C_3$

$$y_1 \geq e^{x_1}, y_2 \geq e^{x_2}$$

$$x = \lambda x_1 + (1-\lambda)x_2$$

$$y = \lambda y_1 + (1-\lambda)y_2$$

convex 함수 정의:

$$e^{\lambda x_1 + (1-\lambda)x_2} \leq \lambda e^{x_1} + (1-\lambda)e^{x_2}$$

$$\therefore y = \lambda y_1 + (1-\lambda)y_2 \geq \lambda e^{x_1} + (1-\lambda)e^{x_2} \geq e^{\lambda x_1 + (1-\lambda)x_2}$$

$$y \geq e^x$$

$\therefore C_3$ 는 convex

3-1(2)

두 점 $(x_1, t_1), (x_2, t_2) \in S$

$$t_1 \geq f(x_1), t_2 \geq f(x_2)$$

$$\lambda \in [0, 1] \text{에 대하여 } x = \lambda x_1 + (1-\lambda)x_2$$

$$t = \lambda t_1 + (1-\lambda)t_2$$

convex 함수 정의: $f(x) = f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2)$

그런데 $t_1 \geq f(x_1), t_2 \geq f(x_2)$

$$\therefore t = \lambda t_1 + (1-\lambda)t_2 \geq \lambda f(x_1) + (1-\lambda)f(x_2) \geq f(x)$$

$$\therefore (x, t) \in S$$

$\therefore S$ 는 convex set

3-2 (1) (a) f, g convex.

의의 $x_1, x_2, \lambda \in [0, 1]$

$$(f+g)(\lambda x_1 + (1-\lambda)x_2) = f(\lambda x_1 + (1-\lambda)x_2) + g(\lambda x_1 + (1-\lambda)x_2)$$

$$\leq \lambda f(x_1) + (1-\lambda)f(x_2) + \lambda g(x_1) + (1-\lambda)g(x_2)$$

$$= \lambda(f(x_1) + g(x_1)) + (1-\lambda)(f(x_2) + g(x_2))$$

$$= \lambda(f+g)(x_1) + (1-\lambda)(f+g)(x_2)$$

$\therefore f+g$ convex

(b) $h(x) = f(Ax+b)$

의의 $x_1, x_2, \lambda \in [0, 1]$

$$h(\lambda x_1 + (1-\lambda)x_2) = f(A(\lambda x_1 + (1-\lambda)x_2) + b)$$

$$= f(\lambda Ax_1 + (1-\lambda)Ax_2 + b)$$

$$= f(\lambda(Ax_1 + b) + (1-\lambda)(Ax_2 + b))$$

$$\leq \lambda f(Ax_1 + b) + (1-\lambda)f(Ax_2 + b)$$

$$= \lambda h(x_1) + (1-\lambda)h(x_2)$$

$\therefore f(Ax+b)$ convex

3-2 (2)

$$\|y\|^2 = y^T y$$

$$f(x) = (Ax-b)^T (Ax-b)$$

의의 $x_1, x_2, \lambda \in [0, 1]$

$$x = \lambda x_1 + (1-\lambda)x_2$$

$$Ax-b = A(\lambda x_1 + (1-\lambda)x_2) - b$$

$$= \lambda(Ax_1 - b) + (1-\lambda)(Ax_2 - b)$$

$$f(x) = \|\lambda(Ax_1 - b) + (1-\lambda)(Ax_2 - b)\|^2$$

因为 M, V 都是矩阵

$$\|\lambda M + (1-\lambda)V\|^2 = \lambda^2 \|M\|^2 + (1-\lambda)^2 \|V\|^2 + 2\lambda(1-\lambda)M^T V$$

$$M^T V \leq \frac{1}{2} (\|M\|^2 + \|V\|^2) \quad \text{由性质 2}.$$

$$\|\lambda M + (1-\lambda)V\|^2 \leq \lambda \|M\|^2 + (1-\lambda) \|V\|^2$$

$$M = Ax_1 - b, \quad V = Ax_2 - b$$

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda \|Ax_1 - b\|^2 + (1-\lambda) \|Ax_2 - b\|^2$$

$$\therefore f(x) = \|Ax - b\|^2 \text{ 是凸的.}$$

문제 4 정보이론 (Information Theory)

4-1. Entropy

확률분포 $p(x, y)$ 가 다음과 같이 주어졌다고 합시다.

$X \setminus Y$	0	1
0	$\frac{1}{3}$	$\frac{1}{3}$
1	0	$\frac{1}{3}$

다음 값들을 구하시오.

(a) $H(X), H(Y)$. $H(X) = -\sum p \log_2 p$

(b) $H(X | Y), H(Y | X)$. $H(X | Y) = \sum p(y) H(X | Y=y)$

(c) $H(X, Y)$. $H(X, Y) = -\sum p(x, y) \log_2 p(x, y)$

(d) $H(Y) - H(Y | X)$.

(e) $I(X; Y)$. $I(X; Y) = H(Y) - H(Y | X)$

(f) (a)부터 (e)까지 구한 양(quantity)들을 벤 다이어그램으로 나타내시오.

4-2. KL-divergence

(a) $D(q \| p) = D(p \| q)$ 가 성립하지 않는 반례를 제시하시오.

(b) $D(p \| q) \geq 0$ 임을 보이시오. (Hint : Jensen's Inequality)

Reference

- Elements of Information Theory (2nd Ed.), T. M. Cover & J. A. Thomas
- Convex Optimization for ML, Prof. Changho Suh

Data Science Lab

담당자: 14 기 박창용, 어희정, 여준호

qkrckddyd0@yonsei.ac.kr

heejung.uh@gmail.com

asap03153@gmail.com

4 -

$$\begin{aligned}(a) \quad H(X) &= -\left(\frac{2}{3} \log_2 \frac{2}{3} + \frac{1}{3} \log_2 \frac{1}{3}\right) \\ &= -\left(\frac{2}{3}(1-\log_2 3) + \frac{1}{3}(-\log_2 3)\right) \\ &= -\left(\frac{2}{3} - \log_2 3\right) = \log_2 3 - \frac{2}{3}\end{aligned}$$
$$H(Y) = \log_2 3 - \frac{2}{3}$$

(b)

$$\begin{array}{ll}Y=0 ; & P(X=0 | Y=0) = \frac{1/3}{1/3} = 1 \\ P= \frac{1}{3} & P(X=1 | Y=0) = 0 \\ \hline Y=1 ; & P(X=0 | Y=1) = \frac{1/3}{2/3} = \frac{1}{2} \\ P= \frac{2}{3} & P(X=1 | Y=1) = \frac{1/3}{2/3} = \frac{1}{2}\end{array}$$
$$\begin{array}{ll}X=0 ; & P(Y=0 | X=0) = \frac{1}{2} \\ P= \frac{2}{3} & P(Y=1 | X=0) = \frac{1}{2} \\ \hline X=1 ; & P(Y=0 | X=1) = 0 \\ P= \frac{1}{3} & P(Y=1 | X=1) = 1\end{array}$$

$$H(X|Y) = \frac{1}{3} \cdot 0 + \frac{2}{3} \cdot 1 = \left(\frac{2}{3}\right)$$
$$H(Y|X) = \frac{2}{3} \cdot 1 + \frac{1}{3} \cdot 0 = \left(\frac{2}{3}\right)$$

$$(c) \quad H(X, Y) = -\frac{1}{3} \cdot \frac{1}{3} \log_2 \frac{1}{3} = \log_2 3$$

$$(d) \quad H(Y) - H(Y|X) = \left(\log_2 3 - \frac{2}{3}\right) - \frac{2}{3} = \log_2 3 - \frac{4}{3}$$

$$(e) \quad I(X; Y) = H(Y) - H(Y|X)$$

$$= \log_2 3 - \frac{4}{3}$$

$$\begin{array}{ll}H(X) & = \log_2 3 - \frac{2}{3} \\ H(Y) & = \log_2 3 - \frac{2}{3} \\ \hline H(X|Y) & = \frac{2}{3} \\ H(Y|X) & = \frac{2}{3}\end{array}$$
$$I(X; Y) = \log_2 3 - \frac{4}{3}$$

4-2 (a)

$$\text{Hypothesis: } p(0) = \frac{1}{2}, \quad p(1) = \frac{1}{2}$$

$$q(0) = \frac{1}{4}, \quad q(1) = \frac{3}{4}$$

$$D(p||q) = \frac{1}{2} \log \frac{1/2}{1/4} + \frac{1}{2} \log \frac{1/2}{3/4}$$
$$= \frac{1}{2} \left(\log \frac{4}{3} \right)$$

\neq

$$D(q||p) = \frac{1}{4} \log \frac{1/4}{1/2} + \frac{3}{4} \log \frac{3/4}{1/2}$$
$$= \frac{1}{4} \log \frac{1}{2} + \frac{3}{4} \log \frac{3}{2}$$

(b) $D(p||q) = \sum p(x) \log \frac{p(x)}{q(x)} = - \sum p(x) \log \frac{q(x)}{p(x)}$

$$r(x) = \frac{q(x)}{p(x)}$$

$$D(p||q) = - \sum p(x) \log r(x)$$
$$= -E_p \left[\log r(x) \right]$$

$$E[\log z] \leq \log(E[z]) \quad -\log z \text{ concave.}$$

$$z = r(x)$$

$$E_p \left[\log \frac{q(x)}{p(x)} \right] \leq \log \left(E_p \left[\frac{q(x)}{p(x)} \right] \right)$$

$$-E_p \left[\log \frac{q(x)}{p(x)} \right] \geq -\log \left(E_p \left[\frac{q(x)}{p(x)} \right] \right)$$

$$D(p||q) \geq "$$

$$\underline{E_p \left[\frac{q(x)}{p(x)} \right]} = \sum p(x) \frac{q(x)}{p(x)} = 1 \quad \Rightarrow -\log(1) = 0.$$

$$\therefore D(p||q) \geq 0$$